ACP (Escalar)

Luis Requeni Zamora

01/02/2023

En este *script* nos centramos en conseguir la matriz de componentes principales a partir de los recuentos para cada uno de nuestros genes en los distintos spots.

OBTENCION DE LA INFORMACIÓN

Originalmente nosotros construimos en el script *BayesSpace (Luis).Rmd* dicha matriz de recuentos a partir de la información proporcionada por el objeto *SingleCellExperiment()* asociado a nuestro banco de datos de melanoma.

```
load("MelanomaZhao.rda")
datos1 <- datos[, -1]
```

No obstante, esa información está también disponible y mucho más clara con la posición de los distintos spots y el nombre de los diferentes genes en la carpeta *ST-Melanoma-Datasets_1*. En concreto nosotros hemos estado trabajando con la muestra *ST_mel1_rep2_counts*.

```
datos2 <- read.table(file = "ST-Melanoma-Datasets_1/ST_mel1_rep2_counts.tsv", sep = '\t', header = TRUE
rownames(datos2) <- datos2[, 1]
datos2 <- datos2[, -1]
datos2 <- as.data.frame(t(datos2))
```

Las dimensiones de los dos datasets son las mismas y hemos realizado una serie de comprobaciones para verificar que realmente recogen la misma información.

```
auxiliar1_datos1 <- apply(datos1, 1, sum)
auxiliar1_datos2 <- as.numeric(apply(datos2, 1, sum))
sum(auxiliar1_datos1 == auxiliar1_datos2)
```

```
## [1] 293
```

```
auxiliar2_datos1 <- apply(datos1, 2, sum)
auxiliar2_datos2 <- as.numeric(apply(datos2, 2, sum))
sum(auxiliar2_datos1 == auxiliar2_datos2)
```

```
## [1] 16148
```

CONSTRUCCION ACP

A partir de la información suplementaria proporcionada en *1. Ts. Zhao 2021* se explica la obtención de dicha matriz de componentes principales que nos permitiría así realizar el estudio aquí planteado para cualquier matriz de recuentos. En concreto se realiza la *ACP* a partir de la normalización de la transformación logarítmica de los 2.000 genes más variables. En el siguiente script, *3. Genes Variables.Rmd* abordamos esa selección de los x genes más variables.

Entendemos que los problemas que obtuvimos hace unas semanas para la práctica de la ACP con todas las variables y los conteos absolutos se podrían solucionar trabajando de esta forma.

Para realizar una primera aproximación nosotros vamos a considerar como más variables aquellos 2.000 genes con una mayor desviación a lo largo de los distintos spots.

```
desviacion <- apply(datos2, 2, sd)
posiciones <- order(desviacion, decreasing = T)[1:2000]
datosPCA <- datos2[, posiciones]
datosPCA <- as.data.frame(apply(datosPCA, 2, as.numeric))
```

Conseguir construir la ACP mediante la función *princomp()* nos permetiría conocer la cantidad de información explicada para un determinado número de componentes principales, así como estudiar cuales son los genes que tienen un mayor protagonismo en dichas componentes y por ende en el futuro modelo de nimble planteado posteriormente.

No obstante dicha función sigue sin funcionar dado que solo es útil cuando el número de observaciones es igual o superior al de variables, de manera que solo podríamos emplearla para un tope de 293 genes variables. Si funciona en cambio la función *prcomp()*, que aunque no devuelve la cantidad de información explicada sí posibilita realizar la PCA.

Vamos a transformar los conteos con valor cero a datos faltantes para no tener problemas en el análisis de componentes principales al realizar la transformación logarítmica.

```
datosPCA <- log(datosPCA)
datosPCA[datosPCA == -Inf] <- 0
# datosPCA[datosPCA == -Inf] <- NA
# colnames(datosPCA) <- paste0("V", 1:2000)
# as.formula(paste("~ ", paste(colnames(datosPCA), collapse= "+")))
Prueba <- prcomp(datosPCA, rank. = 7)
```

Demasiados problemas para poder realizar el ACP. En cualquier caso, vamos a construir un modelo sobre la ACP practicada y comparar con los resultados que teníamos previamente.

```r
y <- as.data.frame(Prueba$x)
Modelo_EjercicioNACP <- nimbleCode(
{
  for(i in 1:293)
  {
    y[i, 1:7] ~ dmnorm(mus[1:7, z[i]], wi_tau[1:7, 1:7])
    wi_tau[1:7, 1:7] <- w[i]*tau[1:7, 1:7]
    w[i] ~ dgamma(2, 2)
    z[i] ~ dcat(omega[1:4])
    # PLANTEAR LA ESTADISTICA ESPACIAL DESDE LA PERSPECTIVA MULTINOMIAL
  }
  omega[1:4] ~ ddirich(dirch_alpha[1:4])
  for (h in 1:4)
  {
    mus[1:7, h] ~ dmnorm(mu_0[1:7], tau_0[1:7, 1:7])
  }
  tau[1:7, 1:7] ~ dwish(wish_V[1:7, 1:7], 8)
}
)

set.seed(1)
tau_ini <- diag(1,7)
z_ini <- sample(c(1, 2, 3, 4), 293, replace = T)

Iniciales_EjercicioNACP <- function()
{
  list(tau = tau_ini,
       z = z_ini,
       mus = matrix(rep(0, 7*4), ncol = 4),
       omega = c(1/4, 1/4, 1/4, 1/4),
       w = rep(1, 293))
}

Parametros_EjercicioNACP <- c("omega", "mus", "z", "tau", "w")
```

```r
nimbleOptions(showCompilerOutput = F)
ModeloNimbleFinalACP <- nimbleMCMC(Modelo_EjercicioNACP, data = list(y = y),
                                   constants = list(mu_0 = rep(0, 7),
                                                    wish_V = diag(1, 7),
                                                    dirch_alpha = c(1, 1, 1, 1),
                                                    tau_0 = diag(0.01, 7)),
                                   inits = Iniciales_EjercicioNACP,
                                   monitors = Parametros_EjercicioNACP,
                                   thin = 10, niter = 20000, nburnin = 4000, nchains = 1,
                                   summary = TRUE, WAIC = TRUE)
```

```r
load("ClasificacionMelanomaZhao.rda")
par(mfrow = c(1, 2))
clusterPlot(ClasificacionMelanomaZhao, palette = c("red", "green", "blue", "pink"))
```

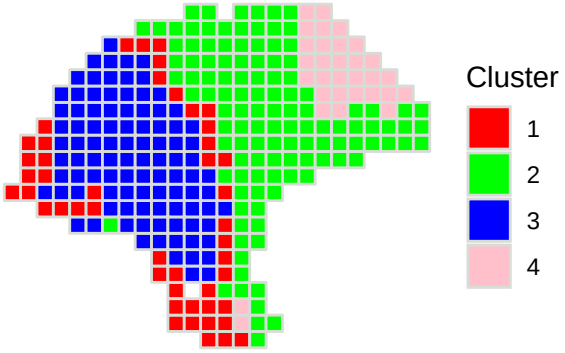


```
ClasificacionMelanomaZhao$spatial.cluster <- as.numeric(ModeloNimbleFinalACP$summary[375:667, 2])
clusterPlot(ClasificacionMelanomaZhao, palette = c("red", "green", "blue", "pink"))
```

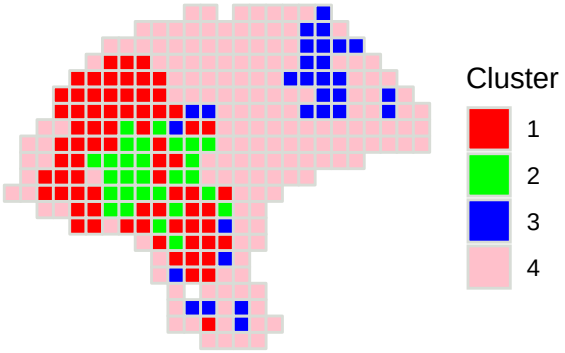

Mucha faena por hacer todavía al respecto.

BIBLIOGRAFIA